# Projet 2026: Statistiques avec R: Modélisation et Prévision de Séries Temporelles

**Instructions:**

- Le projet est a remettre sur moodle au format RMD our QMD, ainsi qu'un fichier .pdf généré à partir de ce fichier.
- La présentation sera prise en compte dans la note.
- Des points seront retirés si le fichier envoyé ne compile pas.
- On justifiera les modèles choisis et si besoins les hypothèses.
- Le rendu doit être compréhensible par une personne n'ayant pas lu l'énoncé.
- On affichera toujours des graphiques plutot que des tables.
- On illustrera les datasets, etc par des graphiques bien choisis.

Dans le cadre de ce projet, vous étudierez la dynamique temporelle de l'utilisation de vélos en libre-service au sein de quatre métropoles françaises (Paris, Lille, Lyon, Marseille). L'objectif est d'appliquer les concepts de modélisation stochastique pour extraire le signal de ces séries et quantifier l'incertitude liée à leurs réalisations futures.

## Données

Vous disposez de l'historique des locations journalières pour les années 2024 et 2025, réparti dans deux fichiers distincts présentant des structures de dates hétérogènes :

- `velos_nord.csv` : Recensements pour Paris et Lille
- `velos_sud.csv` : Recensements pour Lyon et Marseille

## Travail demandé

**1. Restructuration des données (Tidy Data)** Avant toute analyse, vous devrez unifier et restructurer informatiquement ces deux bases pour produire un unique `data.frame` au format Tidy.

**2. Inférence et Prévision pour Paris** En vous concentrant sur la ville de Paris, vous devrez proposer un modèle décrivant la série temporelle. À l'aide de ce modèle, votre objectif final est de fournir des intervalles de prévision à 90 % pour les 7 premiers jours de l'année 2026. Ces intervalles seront construits de manière empirique par simulation.

> **Rappel de définition :** > Soit $(Y_t)_{t\geq 1}$ le processus stochastique modélisant le nombre de locations, et $\mathcal{F}_T$ la filtration représentant l'information disponible jusqu'au 31 décembre 2025 (instant $T$). Pour chaque horizon $h \in \{1, \dots, 7\}$, vous devez déterminer les bornes $\hat{L}_{T+h}$ et $\hat{U}_{T+h}$ telles que la probabilité conditionnelle vérifie :
>
> $$\mathbb{P}\left(\hat{L}_{T+h} \leq Y_{T+h} \leq \hat{U}_{T+h} \,\middle|\, Y_t, t \leq T\right) = 0.90$$

Votre rapport devra inclure une représentation graphique superposant les dernières observations de 2025 et le faisceau de l'intervalle de prévision.

**3. Saisonalité :** La composante saisoniere est-elle la même pour toute les villes? Commentez.